

Predicción de cancelaciones de reservas hoteleras

Memoria del Proyecto Final de Módulo

Máster en IA, Cloud Computing y DevOps • Módulo de Machine Learning y Deep Learning

Manuel Pérez Martínez Joaquín Castro Salas

manugijon@gmail.com jcastrosalas03@gmail.com




Figura 1: Regiones de decisión aprendidas por los cinco modelos sobre el mismo plano 2D supervisado (PLS): el color es la probabilidad estimada de cancelación (azul→rojo) y los puntos, reservas reales del conjunto de prueba. Anticipa visualmente la comparativa de la Sección 4.

Resumen. Las cancelaciones tardías de reservas vacían habitaciones difíciles de revender y distorsionan la previsión de ocupación del hotel. Este trabajo aborda la predicción de la cancelación de una reserva (`is_canceled`) como un problema de **clasificación binaria** sobre $\sim 119\,000$ reservas y 31 características. Partiendo de un análisis exploratorio que detecta y corrige varias fugas de información, se diseña un *pipeline* de preprocesado reproducible (derivación de variables, reducción supervisada de cardinalidad, imputación, estandarización y codificación *one-hot*) y se comparan cinco familias de modelos. El ganador, **XGBoost**, alcanza un **ROC-AUC de 0.9529** sobre un conjunto de prueba independiente. El modelo se sirve mediante una API REST (FastAPI) y se muestra en una interfaz web (Streamlit) que predice e interpreta cada reserva con SHAP.

1. Justificación del problema

Las **cancelaciones de reservas** son uno de los principales problemas económicos del sector hotelero. Una cancelación, sobre todo si llega con poca antelación, deja una habitación vacía que rara vez vuelve a venderse: se pierde el ingreso de esa noche y, con él, parte del margen del establecimiento. El daño va más allá del ingreso directo, porque las cancelaciones **distorsionan la previsión de ocupación** sobre la que se planifican el personal, los aprovisionamientos y los precios, complicando la gestión diaria del hotel.

Para defenderse, los hoteles recurren a prácticas como el *overbooking* (aceptar más reservas que plazas contando con que algunas se cancelarán), la exigencia de depósitos o las campañas de retención. Todas comparten un requisito: solo son seguras y rentables si el hotel puede **anticipar qué reservas tienen más riesgo** de cancelarse. Una estimación fiable de ese riesgo permite actuar de forma selectiva —sobrevender en la medida justa, pedir garantías a las reservas dudosas o intervenir antes de que el cliente cancele— y proteger así los ingresos y la calidad del servicio.

Anticipar las cancelaciones es, por tanto, un problema con un retorno claro y directo para el negocio, lo que justifica el esfuerzo de construir un sistema que las prediga.

Formalmente, representamos la cancelación como una variable aleatoria binaria $Y \in \{0, 1\}$ ($Y = 1$ si la re-

serva se cancela). El sistema estima la probabilidad condicionada $\hat{p}(\mathbf{x}) = P(Y = 1 \mid \mathbf{x})$ a partir del vector de características $\mathbf{x} \in \mathbb{R}^D$, y la decisión final se obtiene aplicando un umbral τ :

$$\hat{Y} = \begin{cases} 1 & \text{si } \hat{p}(\mathbf{x}) \geq \tau, \\ 0 & \text{si } \hat{p}(\mathbf{x}) < \tau, \end{cases} \quad (1)$$

donde τ puede ajustarse según la matriz de costes del hotel, ponderando el coste de un falso negativo (habitación vacía) frente al de un falso positivo (compensación por *overbooking*).

2. Análisis exploratorio de datos

El EDA es la fase en la que exploramos los datos con tablas y gráficos *antes de modelar*, para tomar decisiones con fundamento. Cada hallazgo de esta sección se tradujo en una decisión de diseño concreta del *pipeline*.

2.1. La clase objetivo está desbalanceada

Alrededor del **37 %** de las reservas se cancelan frente a un 63 % que no (Figura 2). Es un desbalance moderado. *Decisión:* usar una **partición estratificada** (preservar ese 37 % en entrenamiento y prueba) y elegir el **ROC-AUC** como métrica principal en lugar de la *accuracy*, que premiaría a un clasificador trivial.




Figura 2: Reparto de la clase objetivo. El desbalance ($\sim 37 / 63$) motiva la estratificación y el uso de ROC-AUC.




Figura 3: `required_car_parking_spaces`: el 0 % de cancelación con plaza asignada persiste dentro de las reservas cancelables, revelando una fuga de *check-in*, no un predictor.

2.2. Columnas que “hacen trampa” (fuga de información)

La **fuga de información** (*data leakage*) ocurre cuando el modelo usa, sin querer, datos que revelan la respuesta o que no existirían en el momento de predecir.

`reservation_status` vale `Canceled/No-Show` *exactamente* cuando `is_canceled = 1`, y junto con `reservation_status_date` describe lo que ocurrió *después* de decidir la cancelación. *Decisión:* eliminar ambas columnas; de lo contrario el modelo “vería la respuesta” y obtendría un acierto del ~ 100 % engañoso e inútil.

Más sutil es `required_car_parking_spaces` (Figura 3): ninguna reserva con plaza de parking se cancela (0 %), pero esa relación es *determinista* precisamente porque el dato *solo se conoce en el check-in*, cuando el cliente ya se ha presentado y, por tanto, no ha cancelado. El 0 % se mantiene incluso restringiendo a las reservas cancelables (`deposit_type = No Deposit`), lo que descarta que sea una mera correlación con el depósito. *Decisión:* **eliminarla** del modelo: en el momento de puntuar una reserva futura ese valor no existe. Era la principal causa del optimismo de versiones anteriores.

La misma lógica descarta `assigned_room_type`, el tipo de habitación **finalmente asignado**: solo se conoce en el *check-in*. Cuando la habitación asignada




Figura 4: Porcentaje de valores ausentes por columna. `company` está casi totalmente vacía, pero su ausencia es informativa.

differe de la reservada la cancelación cae al 5.4 % (frente al 41.6 % cuando coinciden), porque reasignar habitación implica que el cliente se presentó. Se elimina; `reserved_room_type` —la que el cliente elige al reservar— sí se conserva.

También se descarta `arrival_date_year`: apenas discrimina (la tasa es casi idéntica los tres años), no generaliza a años futuros no vistos y va confundido con la estación (correlación -0.54 con la semana del año, porque el dataset cubre años parciales). La señal estacional ya la recogen `arrival_date_month` y `week_number`, que sí se repiten cada año.

2.3. Valores ausentes

Cuatro columnas presentan huecos (Figura 4). En lugar de descartarlas, se tratan según su naturaleza: `company` (~ 94 % vacía) y `agent` se conservan como categorías (el hueco pasa a una etiqueta propia), `country` se imputa con una constante y `children` con 0. La imputación se aprende *solo en entrenamiento* para no filtrar información del test.

2.4. La ausencia es señal, no ruido

Que una reserva no tenga `company` o `agent` asignado no es un simple hueco: es una señal con valor predictivo (Figura 5). Las reservas **con** empresa cancelan mucho menos que las que no la tienen; con `agent` la señal va en sentido contrario. *Decisión:* derivar dos indicadores binarios `has_company` y `has_agent` que capturan explícitamente esa diferencia, en vez de descartar las columnas.

2.5. Variables numéricas

`lead_time` (días de antelación) es la numérica más relacionada con la cancelación: a más antelación, mayor probabilidad de cancelar, de forma casi monótona por tramos (Figura 6). `total_of_special_requests` se relaciona a la inversa (clientes más comprometidos cancelan menos). Como las variables conviven en escalas muy distintas, se aplica **estandarización** (media 0, desviación 1) para que ningún rango domine artificialmente. Esta transformación **no perjudica a ningún modelo**: los basados en árboles (Random Forest y XGBoost, el ganador) son insensibles a la escala —deciden




Figura 5: Tasa de cancelación según la presencia/ausencia de `company` y `agent`. La ausencia discrimina, lo que justifica las variables derivadas `has_company`/`has_agent`.




Figura 6: Tasa de cancelación por tramos de `lead_time`: relación creciente y casi monótona, la señal numérica más fuerte.

por cortes y el orden de los valores no cambia—, mientras que la regresión logística y la red neuronal sí se benefician de ella (convergen mejor y sus coeficientes son comparables). Por eso, aunque matemáticamente algunas variables no la necesiten, la aplicamos de forma **global**: simplifica el *pipeline* y no introduce ningún efecto negativo.

2.6. Variables categóricas y codificación

`deposit_type` = Non Refund (depósito no reembolsable) tiene una tasa de cancelación **cercana al 99 %** (Figura 7): la variable más predictiva del conjunto. Las categóricas se transforman a números mediante codificación **one-hot** (`OneHotEncoder`), una columna binaria por categoría.

El problema es que `country` (177 países), `agent` (333 agencias) y `company` (352) tienen **altísima cardinalidad** (Figura 8): un *one-hot* directo crearía cientos de columnas casi vacías, disparando la dimensionalidad y el sobreajuste. **Decisión:** aplicar una **reducción supervisada de cardinalidad** antes del *one-hot*, implementada como un **transformador propio** (`RareCategoryGroupier`, ya que `scikit-learn` no incluye ninguno que agrupe categorías según el *target*). Se conservan las categorías con soporte suficiente ($n \geq 100$) y tasa de cancelación **extrema en cualquiera de los dos sentidos** (muy alta o muy baja, con umbral adaptativo por variable: > 0.6 o < 0.3 de la tasa máxima de esa columna); el resto se agrupa en **Otros**. La selección usa el objetivo, así que se aprende




Figura 7: `deposit_type`: el depósito no reembolsable casi garantiza la cancelación. Señal categórica dominante.




Figura 8: Reducción supervisada de cardinalidad: de cientos de categorías a unas pocas columnas con señal, paso previo al `OneHotEncoder`.

de **solo con el *train*** y se reaplica idéntica en test e inferencia (sin fuga). Lo verificamos entrenando los 5 modelos con y sin la reducción: pasamos de **902 a 144 columnas** sin coste para **XGBoost** (ROC-AUC 0.9529 vs. 0.9573, dentro del ruido) y con mejora para **Random Forest** (0.9363 vs. 0.9221). Así se preserva la señal de las categorías relevantes sin pagar el coste dimensional. La Figura 9 muestra, en sus tres paneles, *qué* categorías sobreviven en cada variable, ordenadas por tasa de cancelación: en rojo las de **alto riesgo** (tasa > 0.6 del máximo de la columna) y en azul las **muy fiables** (< 0.3 del máximo). El resto, sin señal extrema, se agrupa en **Otros**.

Por último, se sanea el conjunto eliminando registros claramente erróneos: ~ 180 reservas sin ningún huésped (`adults+children+babies = 0`) y dos *outliers* flagrantes en la tarifa diaria `adr` —un valor **negativo** (-6.4) y otro **desorbitado** (5400)— que solo pueden ser errores de captura.

3. Diseño del sistema

El sistema no se construyó de una vez, sino siguiendo un **arco de desarrollo** en tres etapas que va de la exploración libre a un servicio en producción. La progresión es deliberada: cada etapa valida sus decisiones antes de comprometerlas en la siguiente.






Figura 9: Categorías conservadas por la reducción supervisada en las tres variables de alta cardinalidad, una bajo otra por tratar lo mismo: `country` (14 conservadas; Portugal y Angola, alto riesgo), `company` (10) y `agent`. Ordenadas por tasa de cancelación —en rojo el alto riesgo, en azul las muy fiables; el resto va a `Otros`—. En `agent` se muestran solo las 8 que más y las 8 que menos cancelan (de las ~55 conservadas), por legibilidad.

3.1. Etapa 1 — Exploración con cuadernos

La fase exploratoria se realizó en *notebooks* autónomos, donde se analizaron los datos y se prototiparon a mano las reglas de preparación y los primeros modelos. Es el terreno para equivocarse barato: probar codificaciones, detectar y descartar variables con fuga, medir el efecto del balanceo de clases, etc. De aquí salieron ya




Figura 10: El *pipeline* de ML de extremo a extremo (flujo vertical): preprocesado, entrenamiento y evaluación de los modelos, registro del ganador e inferencia. El preprocesado se aprende del entrenamiento y se persiste junto al modelo, de modo que predecir reproduce exactamente las transformaciones del entrenamiento.

validadas todas las decisiones del EDA de la sección anterior.

3.2. Etapa 2 — Generalización en un *pipeline*

Lo aprendido se consolidó en un *pipeline* de preprocesado reproducible que encadena, como pasos sucesivos, la derivación de variables informativas (entre ellas `has_company/has_agent`), la reducción supervisada de cardinalidad de las categóricas, la imputación de huecos, la estandarización de las numéricas y la codificación *one-hot*. La clave metodológica es que el preprocesado se **ajusta únicamente con los datos de entrenamiento** y se guarda *junto al modelo*: así se evita cualquier fuga hacia el conjunto de prueba y se garantiza que la inferencia replica exactamente el entrenamiento. Sobre ese preprocesado común se entrenan y comparan, en igualdad de condiciones, **cinco familias de modelos** —regresión logística (línea base), árbol de decisión, Random Forest, XGBoost y una red neuronal multicapa con **Keras/TensorFlow** (densas $64 \rightarrow 32 \rightarrow 16$ con *dropout* y salida sigmoide)—, con sus hiperparámetros optimizados por validación cruzada. La Figura 10 resume este flujo de extremo a extremo.

¿Qué es la validación cruzada? En lugar de fiar la elección de hiperparámetros a una única partición, la *validación cruzada* (*k-fold*) divide el entrenamiento en *k* bloques: entrena con *k* − 1 y mide en el bloque restante, rotando hasta que cada bloque ha servido una vez de validación. El promedio de las *k* medidas es una estimación **más estable y menos optimista** del rendimiento, y evita ajustar los hiperparámetros al




Figura 11: Arquitectura en cuatro planos. El dato alimenta la experimentación local, que emite un modelo versionado (MLflow/DagsHub) y un artefacto en el repositorio; de ahí, el despliegue continuo publica la API y la interfaz que consume el usuario. La flecha discontinua indica que el servicio puede cargar el modelo directamente desde el registro.

azar de un único reparto. La configuración finalmente elegida es la que mejor puntúa en ese promedio.

3.3. Etapa 3 — Productivización

Finalmente, el modelo ganador se lleva a producción. El artefacto se persiste y se **versiona en un registro de modelos** (MLflow), el código y el modelo viven en un repositorio Git, y dos servicios desplegados de forma continua exponen el sistema al usuario: una **API REST** (FastAPI) que sirve las predicciones y una **interfaz web** (Streamlit) que permite explorar los resultados y predecir reservas concretas consumiendo esa API. La Figura 11 resume la arquitectura en cuatro planos —experimentación, trazabilidad, repositorio y servicio— que pueden evolucionar de forma independiente: una nueva iteración de modelado solo afecta a los dos primeros, y un cambio de interfaz, solo al último.

Despliegue público. El sistema está accesible en línea (servicios en *tier* gratuito, pueden tardar unos segundos en activarse tras inactividad):

- **Interfaz web** (Streamlit): <https://ml-hotel-cancellations-manupm87.streamlit.app>
- **API REST** (FastAPI, Swagger): <https://pontia-api-fi8t.onrender.com/docs>
- **Experimentos y registro de modelos** (MLflow en DagsHub): <https://dagshub.com/manupm87/pontia-ml.mlflow>

3.4. Interpretabilidad

Un sistema que decide sobre el negocio debe poder **explicar** sus decisiones, no solo acertar. Por eso el diseño incorpora interpretabilidad con **SHAP**, una técnica que reparte cada predicción entre las variables, indicando cuánto empuja cada una hacia “cancela” o “no cancela”, a nivel **global** (qué pesa en general) y **local** (por qué *esa* reserva concreta).

A nivel global. El resumen SHAP (Figura 12a) lo encabeza `deposit_type = Non Refund`, seguido del país (Portugal, `country_PRT`), el `lead_time`, el total de peticiones especiales, el segmento de mercado (Online TA) y las cancelaciones previas. Aparece también `agent_Otros`, lo que confirma que el grupo de agencias condensado por la reducción de cardinalidad sí aporta señal. La importancia interna del Random Forest (Figura 12b) ordena las variables de forma muy

parecida: que dos familias de modelos distintas coincidan en lo que importa refuerza que el sistema aprende patrones reales, no artefactos de un algoritmo concreto.

A nivel local. SHAP también explica reservas individuales. La Figura 13 desglosa una reserva de **altísimo riesgo** ($p \approx 1$): partiendo del riesgo medio, el depósito no reembolsable (+3.45) y las cancelaciones previas (+2.87) la empujan con fuerza hacia “cancela”, mientras que solo unos pocos factores tiran ligeramente en sentido contrario. Este tipo de explicación es lo que permite **justificar al negocio** por qué una reserva concreta se marca como dudosa.

4. Resultados y elección final

La evaluación se realiza sobre un **conjunto de prueba** de 23 713 reservas (20 % del total) que el modelo no usó al entrenar (Tabla 1). Las cifras corresponden a los hiperparámetros ya optimizados.

4.1. La métrica: ROC-AUC


La métrica principal es el **ROC-AUC** (área bajo la curva ROC). En vez de medir cuántas predicciones acierta con un umbral fijo, evalúa la capacidad del modelo de **ordenar** las reservas por riesgo: equivale a la probabilidad de que, tomadas al azar una reserva cancelada y otra no, el modelo asigne mayor riesgo a la cancelada. Vale 0.5 si no distingue mejor que el azar y 1 si las ordena perfectamente. Se eligió por tres razones alineadas con el caso de uso:

- **Robusta al desbalance:** a diferencia de la *accuracy*, no se deja engañar por la clase mayoritaria (un modelo que dijera “nadie cancela” acertaría el 63 % pero sería inútil).
- **Independiente del umbral:** no fija de antemano a partir de qué probabilidad se considera “cancelará”, de modo que el hotel puede mover ese punto de corte según su coste —más agresivo para llenar plazas, más prudente si una falsa alarma es cara.
- **Comparable:** da una cifra única y homogénea para ordenar los cinco modelos.

Como el valor de negocio está precisamente en *priorizar* reservas por riesgo (para *overbooking*, depósitos o retención), una métrica de **ordenación** es la más adecuada. Se reportan además *recall* y precisión por su lectura directa para el negocio.



(a) Resumen SHAP global (*beeswarm*) del modelo ganador: aporte y dirección de cada variable. Confirma los hallazgos del EDA.



(b) Importancia de variables del Random Forest: coincide en lo esencial con el *ranking* SHAP del ganador (depósito, *lead_time*, país, cancelaciones previas...).

Figura 12: Interpretabilidad global por dos familias de modelos: SHAP sobre el XGBoost ganador (a) y la importancia interna del Random Forest (b). Su coincidencia refuerza que el sistema aprende patrones reales, no artefactos de un algoritmo.




Figura 13: Explicación local (*waterfall* SHAP) de una reserva de ejemplo con alta probabilidad de cancelación: contribución de cada variable a su predicción.

Formalmente, el ROC-AUC es el área bajo la curva que enfrenta la tasa de verdaderos positivos $TPR(\tau)$ frente a la de falsos positivos $FPR(\tau)$ al variar el umbral, $AUC = \int_0^1 TPR(FPR^{-1}(u)) du$, y equivale al estadístico de Mann-Whitney^[1]: si X_1 es el riesgo predicho

Modelo	Acc.	Prec.	Rec.	F1	ROC-AUC
XGBoost	0.881	0.859	0.814	0.836	0.9529
Red neuronal	0.861	0.845	0.769	0.805	0.9353
Random Forest	0.856	0.872	0.720	0.789	0.9338
Árbol decisión	0.846	0.822	0.747	0.783	0.9235
Reg. logística	0.803	0.723	0.764	0.743	0.8862

Cuadro 1: Métricas sobre el conjunto de prueba. XGBoost domina en la métrica principal (ROC-AUC) y en F1.

para una reserva cancelada al azar y X_0 el de una no cancelada,

$$AUC = P(X_1 > X_0). \quad (2)$$

Es decir, mide directamente la probabilidad de ordenar correctamente un par cancelada/no-cancelada, independientemente del umbral.

4.2. El modelo ganador

Se elige XGBoost (ROC-AUC = 0.9529). Supera al resto en la métrica principal y en F1, y aun así entrena en pocos segundos. En términos de negocio, con el umbral por defecto detecta el **81 % de las cancelaciones reales** (*recall* 0.81) con una **precisión del 86 %**: un buen equilibrio para actuar sin generar demasiadas falsas alarmas. El Random Forest es el más conservador (más precisión, menos *recall*), preferible si una falsa alarma fuese muy costosa. Las curvas ROC (Figura 14) confirman esta jerarquía.

Su ventaja teórica está en cómo optimiza: en cada ite-




Figura 14: Curvas ROC comparativas. Cuanto más cerca de la esquina superior izquierda, mejor; XGBoost domina al resto.




Figura 15: Matriz de confusión del modelo ganador (XGBoost) sobre el conjunto de prueba: los aciertos están en la diagonal.

ración t aproxima la pérdida con una expansión de Taylor de segundo orden y penaliza la complejidad del árbol, minimizando el objetivo regularizado de Chen y Guestrin [2]

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^n \left[g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t^2(\mathbf{x}_i) \right] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2, \quad (3)$$

donde g_i y h_i son los gradientes de primer y segundo orden de la pérdida en la predicción previa, T es el número de hojas, w_j sus pesos y γ, λ regularizadores. Esta penalización explícita de la complejidad explica su robustez y eficiencia en CPU.

La matriz de confusión del ganador (Figura 15) desglosa su comportamiento sobre las 23 713 reservas de prueba: detecta **7193** de las 8835 cancelaciones reales y se le escapan 1642 (los falsos negativos), generando solo **1178** falsas alarmas sobre las reservas que no se cancelaban.

5. Reflexión crítica: limitaciones y mejoras

Limitaciones actuales.

- **Validación temporal pendiente:** la partición es aleatoria. Como las reservas tienen fecha (2015–2017), una división *por tiempo* (entrenar con el pasado, probar con el futuro) sería más realista y probablemente daría una cifra algo más baja, pero más fiable.
- **Desbalance sin tratamiento explícito:** se aborda con estratificación y una métrica adecuada, no con técnicas de reequilibrado. El balanceo (`class_weight`, SMOTE) se exploró y sube el *recall* a costa de precisión, pero deja el ROC-AUC casi igual, por lo que no se incorpora al *pipeline* de producción.
- **Cardinalidad simplificada:** agrupar las categorías raras en *Otros* sacrifica parte de su información individual.
- **Umbral fijo en 0.5:** no se ha ajustado a un objetivo de negocio concreto.

Líneas de mejora.

- **Un modelo por hotel.** El EDA mostró que el *City Hotel* y el *Resort Hotel* se comportan casi como dos negocios distintos, con estacionalidad y tasa de cancelación diferentes. Entrenar un modelo especializado para cada uno, en lugar de uno único, podría capturar mejor sus patrones propios, a costa de mantener y servir dos modelos.
- **Validación temporal** para cifras más fiables que la partición aleatoria.
- **Embeddings** para las categóricas de alta cardinalidad (`country`, `agent`), que preservarían más señal que el agrupamiento.
- **Infraestructura con más memoria** (p. ej. Hugging Face Spaces) para reactivar la carga del modelo desde el *Model Registry* de MLflow en el despliegue público, hoy limitado por la RAM del *tier* gratuito.

6. Conclusiones

Este trabajo ha abordado la predicción de cancelaciones de reservas hoteleras como un problema de clasificación binaria de principio a fin: desde un análisis exploratorio que **detecta y corrige fugas de información** —el origen del optimismo de versiones previas— hasta un sistema desplegado en producción. La decisión metodológica más relevante fue *anteponer la honestidad al número*: eliminar las variables de *check-in* (`required_car_parking_spaces`, `assigned_room_type`) rebaja el ROC-AUC de un 0.9614 engañoso a un 0.9529 **realista**, una cifra que sí mide lo que el modelo podrá hacer ante una reserva futura.

De las cinco familias comparadas en igualdad de condiciones, **XGBoost** resulta la ganadora, combinando la mejor métrica de ordenación con un coste de entrenamiento mínimo. Un componente relevante del *pipeline* es el `RareCategoryGrouper`, un transformador propio —no disponible en `scikit-learn`— que apli-

ca una reducción supervisada de cardinalidad: ajustado solo en entrenamiento, conserva las categorías con señal de cancelación extrema en `country`, `agent` y `company` y agrupa el resto, reduciendo de 902 a 144 columnas sin pérdida de poder predictivo. Junto con las variables derivadas de la ausencia informativa (`has_company/has_agent`), preserva la mayor parte de la señal. La interpretabilidad con SHAP confirma, además, que el modelo se apoya en factores con sentido de negocio (depósito no reembolsable, país, antelación, cancelaciones previas), no en artefactos.

El resultado es un sistema reproducible y **accesible en línea** (API REST, interfaz web y registro de experimentos), que no solo predice sino que *explica* cada decisión. Entre las líneas de mejora, la más respaldada por el análisis es **separar el sistema en dos modelos especializados**, uno por tipo de hotel (*City* y *Resort*): el EDA mostró que se comportan como negocios distintos, con estacionalidad y tasa de cancelación propias, por lo que un modelo por hotel capturaría mejor sus patrones. Otras vías —validación temporal o *embeddings* para la alta cardinalidad— complementan ese camino más allá del alcance de esta memoria.

Bibliografía

- [1] *Receiver operating characteristic* (curva ROC, AUC y su equivalencia con el estadístico de Mann–Whitney). Wikipedia (consultado en junio de 2026). https://en.wikipedia.org/wiki/Receiver_operating_characteristic
- [2] T. Chen y C. Guestrin. *XGBoost: A Scalable Tree Boosting System*. Proceedings of the 22nd ACM SIGKDD, 2016. <https://doi.org/10.1145/2939672.2939785>
- [3] S. M. Lundberg y S.-I. Lee. *A Unified Approach to Interpreting Model Predictions*. Advances in Neural Information Processing Systems (NeurIPS), 2017.
- [4] N. Antonio, A. de Almeida y L. Nunes. *Hotel booking demand datasets*. Data in Brief, vol. 22, 2019. <https://doi.org/10.1016/j.dib.2018.11.126>